

Machine Learning

LOGISTIC REGRESSION, K-NEAREST NEIGHBOR, NAIVE BAYES, DECISION TREE



KELOMPOK 6

ANGGOTA



Iffatun Nisa Nasrullah

(2208107010009)

Muhammad Bintang Indra Hidayat

(2208107010023)

Qandila Ahmara

(2208107010039)

Alhusna Hanifah

(2208107010060)

Farhanul Khair

(2208107010076)

1. LATAR BELAKANG & DATASET

- **Sindrom Metabolik** adalah kumpulan kondisi medis yang meningkatkan risiko penyakit jantung dan diabetes.
- Deteksi dini penting untuk mencegah komplikasi.
- Proyek ini bertujuan membandingkan 4 algoritma klasifikasi untuk mengidentifikasi sindrom metabolik.

Informasi Dataset


Sumber: Kaggle (2023),
"Metabolic Syndrome
Dataset"

Target/Label:

MetabolicSyndrome (0/1)

Variable yang digunakan:

seqn, age, Sex, Marital,
Income, Race, WaistCirc,
BMI, Albuminuria, UrAlbCr,
UricAcid, BloodGlucose, HDL,
Triglycerides,
MetabolicSyndrome.



TAHAPAN PROJECT

- Membagi data (train/test split)
- Membangun model: Logistic Regression, KNN, Naive Bayes, Decision Tree

- Hyperparameter tuning (GridSearchCV)
- Analisis perbandingan performa model
- Kesimpulan dan rekomendasi

PEMBANGUNAN MODEL

TUNING DAN ANALISIS

EKSPLORASI DAN PRA-PEMROSESAN DATA

EVALUASI MODEL

- Memahami struktur dataset dan distribusi fitur
- Menangani nilai hilang
- Normalisasi dan encoding variabel

- Mengukur akurasi, log loss, precision, recall, f1-score
- Visualisasi confusion matrix & classification report



2.EKSPLORASI DAN PRA-PEMROSESAN

STATISTIK DESKRIPTIF DATA

- Menampilkan ringkasan statistik numerik menggunakan df.describe()
- Metrik utama: mean, std, min, max, kuartil (Q1-Q3)
- Digunakan untuk memahami distribusi, rentang nilai, dan mendeteksi potensi outlier
- Penting sebagai dasar untuk proses normalisasi dan pemilihan fitur

```
# Calculate descriptive statistics for the numerical columns
df.describe()
```

	seqn	Age	Income	WaistCirc	BMI	Albuminuria	UrAlbCr	UricAcid	BloodGlucose	HDL	Triglycerides	MetabolicSyndrome
count	2401.000000	2401.000000	2284.000000	2316.000000	2375.000000	2401.000000	2401.000000	2401.000000	2401.000000	2401.000000	2401.000000	2401.000000
mean	67030.674302	48.691795	4005.253940	98.307254	28.702189	0.154102	43.626131	5.489046	108.247813	53.369429	128.125364	0.342357
std	2823.565114	17.632852	2954.032186	16.252634	6.662242	0.422780	258.272829	1.439358	34.820657	15.185537	95.322477	0.474597
min	62161.000000	20.000000	300.000000	56.200000	13.400000	0.000000	1.400000	1.800000	39.000000	14.000000	26.000000	0.000000
25%	64591.000000	34.000000	1600.000000	86.675000	24.000000	0.000000	4.450000	4.500000	92.000000	43.000000	75.000000	0.000000
50%	67059.000000	48.000000	2500.000000	97.000000	27.700000	0.000000	7.070000	5.400000	99.000000	51.000000	103.000000	0.000000
75%	69495.000000	63.000000	6200.000000	107.625000	32.100000	0.000000	13.690000	6.400000	110.000000	62.000000	150.000000	1.000000
max	71915.000000	80.000000	9000.000000	176.000000	68.700000	2.000000	5928.000000	11.300000	382.000000	156.000000	1562.000000	1.000000




2.EKSPLORASI DAN PRA-PEMROSESAN


VISUALISASI DEMOGRAFI RESPONDEN

Visualisasi ini bertujuan untuk memahami komposisi data berdasarkan atribut kategorikal seperti jenis kelamin dan status pernikahan. Analisis ini penting untuk melihat potensi ketidakseimbangan data yang dapat memengaruhi hasil model.

**Jenis Kelamin (Sex): distribusi seimbang
(50% Male, 50% Female)**



Status Pernikahan (Marital): mayoritas menikah (58%), diikuti single (21%)



2.EKSPLORASI DAN PRA-PEMROSESAN

PIPELINE PRA PEMROSESAN DATA

Pra-Pemrosesan Kolom Numerik

Untuk fitur numerik, dilakukan:

- Imputasi nilai hilang menggunakan mean
- Standardisasi menggunakan StandardScaler agar fitur memiliki skala seragam

```
# Pipeline untuk kolom numerik: imputasi + scaling
numeric_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy="mean")),
    ('scaler', RobustScaler())
])
```

Pra-Pemrosesan Kolom Kategorikal

Fitur kategorikal seperti Sex, Race, dan Marital diolah dengan:

- Imputasi nilai hilang dengan modus (nilai terbanyak)
- Transformasi menggunakan One-Hot Encoding atau Ordinal Encoding

```
# Pipeline untuk kolom kategorikal: imputasi + one-hot encoding
categorical_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy="most_frequent")),
    ('onehot', OneHotEncoder(handle_unknown='ignore'))
])
```

Label Encoding Pada Target

Variabel target MetabolicSyndrome dikonversi dari bentuk kategori ke angka dengan label encoding.

```
# Label encoding for the target variable
le = LabelEncoder()
y_train_preprocessed = le.fit_transform(y_train)
y_test_preprocessed = le.transform(y_test)

# Apply preprocessing
X_train_preprocessed = preprocessor.fit_transform(X_train)
X_test_preprocessed = preprocessor.transform(X_test)
```





2.EKSPLORASI DAN PRA-PEMROSESAN

VISUALISASI DAN ANALISIS AWAL (EDA)

Visualisasi Distribusi Fitur Numerik

Histogram dan density plot digunakan untuk memvisualisasikan distribusi kolom Age dan Income.




2.EKSPLORASI DAN PRA-PEMROSESAN

VISUALISASI DAN ANALISIS AWAL (EDA)

Korelasi Antar Fitur

Matriks korelasi digunakan untuk melihat hubungan antar fitur numerik. Korelasi tinggi antar fitur bisa menyebabkan multikolinearitas, yang dapat memengaruhi model seperti Logistic Regression.



3. IMPLEMENTASI MODEL

Logistic Regression

Merupakan model linier yang digunakan untuk klasifikasi biner. Model ini menghitung probabilitas suatu data termasuk dalam kelas tertentu dengan menggunakan fungsi sigmoid. Logistic Regression sering dijadikan baseline karena sederhana dan efisien.

K-Nearest Neighbor (KNN)

Merupakan algoritma non-parametrik yang memprediksi kelas suatu data berdasarkan mayoritas kelas dari sejumlah tetangga terdekat. KNN tidak melakukan pelatihan eksplisit, namun sangat bergantung pada jarak antar data di ruang fitur.

Naive Bayes

Model probabilistik yang didasarkan pada Teorema Bayes dengan asumsi bahwa fitur saling bebas (independen). Meskipun asumsi tersebut jarang benar di dunia nyata, model ini cepat, sederhana, dan cukup efektif untuk klasifikasi awal.


Decision Tree

Merupakan model linier yang digunakan untuk klasifikasi biner. Model ini menghitung probabilitas suatu data termasuk dalam kelas tertentu dengan menggunakan fungsi sigmoid. Logistic Regression sering dijadikan baseline karena sederhana dan efisien.

MEMBANGUN MODEL



LOGISTIC REGRESSION



```
[ ] lr = LogisticRegression(C=1, solver='liblinear', max_iter=1000)
    lr.fit(X_train_preprocessed, y_train_preprocessed)
    y_pred_lr = lr.predict(X_test_preprocessed)
    proba_lr = lr.predict_proba(X_test_preprocessed) # Logistic Regression
    loss_lr = log_loss(y_test_preprocessed, proba_lr)
    accuracy_lr = accuracy_score(y_test_preprocessed, y_pred_lr)
    print("Logistic Regression Accuracy:", accuracy_lr)
    print("Log Loss (Logistic Regression):", loss_lr)
```

```
Logistic Regression Accuracy: 0.7879417879417879
Log Loss (Logistic Regression): 0.4538910461034836
```



K-NEAREST NEIGHBOR (KNN)

```
knn = KNeighborsClassifier(n_neighbors=9, weights='distance', metric='manhattan')
knn.fit(X_train_preprocessed, y_train_preprocessed)
y_pred_knn = knn.predict(X_test_preprocessed)
accuracy_knn = accuracy_score(y_test_preprocessed, y_pred_knn)
print("KNN Accuracy:", accuracy_knn)
# Untuk KNN
proba_knn = knn.predict_proba(X_test_preprocessed)
loss_knn = log_loss(y_test_preprocessed, proba_knn)
print("Log Loss (KNN):", loss_knn)
```

```
KNN Accuracy: 0.7733887733887734
Log Loss (KNN): 0.5527488981296905
```

MEMBANGUN MODEL



NAIVE BAYES



```
nb = GaussianNB(var_smoothing=1e-9)
nb.fit(X_train_preprocessed, y_train_preprocessed)
y_pred_nb = nb.predict(X_test_preprocessed)
loss = log_loss(y_test_preprocessed, y_pred_nb)
proba_nb = nb.predict_proba(X_test_preprocessed)
loss_nb = log_loss(y_test_preprocessed, proba_nb)
accuracy_nb = accuracy_score(y_test_preprocessed, y_pred_nb)
print("Naive Bayes Accuracy:", accuracy_nb)
print("Log Loss (Naive Bayes):", loss_nb)
```

Naive Bayes Accuracy: 0.762993762993763
Log Loss (Naive Bayes): 1.255702596516781



DECISION TREE

```
dt = DecisionTreeClassifier(max_depth=5, min_samples_split=5, criterion='gini')
dt.fit(X_train_preprocessed, y_train_preprocessed)
y_pred_dt = dt.predict(X_test_preprocessed)
accuracy_dt = accuracy_score(y_test_preprocessed, y_pred_dt)
print("Decision Tree Accuracy:", accuracy_dt)
proba_dt = dt.predict_proba(X_test_preprocessed)
loss_dt = log_loss(y_test_preprocessed, proba_dt)
print("Log Loss (Decision Tree):", loss_dt)
```


Decision Tree Accuracy: 0.8523908523908524
Log Loss (Decision Tree): 0.41511958555000233

4.EVALUASI MODEL

1.EVALUASI LOGISTIC REGRESSION



Confusion matrix menunjukkan model Logistic Regression mengklasifikasikan dengan benar 275 data negatif (TN) dan 104 data positif (TP), serta salah memprediksi 34 data negatif sebagai positif (FP) dan 68 data positif sebagai negatif (FN). Laporan menunjukkan precision 0.80 (negatif) dan 0.75 (positif), dengan f1-score rata-rata 0.78, menandakan performa model cukup baik namun perlu peningkatan pada kelas positif.




```
[ ] class_report = classification_report(y_test_preprocessed, y_pred_lr)
    print(class_report)
```



	precision	recall	f1-score	support
0	0.80	0.89	0.84	309
1	0.75	0.60	0.67	172
accuracy			0.79	481
macro avg	0.78	0.75	0.76	481
weighted avg	0.78	0.79	0.78	481


2. EVALUASI K-NEAREST NEIGHBOR

Visualisasi ini menampilkan hasil evaluasi model KNN dalam bentuk matriks konfusi, yang menggambarkan akurasi prediksi model terhadap kelas aktual. Dari matriks terlihat bahwa model lebih efektif dalam mengidentifikasi kelas negatif (TN = 277) dibandingkan kelas positif (TP = 200), dengan sedikit kesalahan prediksi (FP = 32, FN = 25). Terlihat bahwa model cenderung bias terhadap kelas 0 (precision dan recall tinggi), tetapi kurang efektif untuk kelas 1 (recall hanya 55%).



3. EVALUASI NAIVE BAYES


Matriks dibawah mengungkap kelemahan model dalam memprediksi kelas negatif (TN rendah: 73, FN tinggi: 99). Dominasi kelas positif menyebabkan bias prediksi. model Naive Bayes cenderung bias ke kelas 0 (precision dan recall tinggi) tetapi gagal menangkap kelas 1 (recall hanya 58%). Akurasi 76% kurang informatif karena ketidakseimbangan data.



	precision	recall	f1-score	support
0	0.79	0.87	0.82	309
1	0.71	0.58	0.63	172
accuracy			0.76	481
macro avg	0.75	0.72	0.73	481
weighted avg	0.76	0.76	0.76	481


4. EVALUASI DECISION TREE

Matriks konfusi (asumsi: TP=200, TN=250) mengonfirmasi bahwa model seimbang dalam memprediksi kedua kelas. Namun, perlu dicek kembali nilai aktual FP dan FN untuk memastikan tidak ada bias tersembunyi. Decision Tree sebagai model terbaik dengan akurasi 85% dan F1-Score seimbang (0.88 kelas 0, 0.81 kelas 1). Performa kuat pada recall kelas 1 (0.88) membuatnya cocok untuk aplikasi yang prioritaskan deteksi kasus positif. Nilai precision 1.75 perlu diverifikasi.



HASIL PERBANDINGAN KINERJA KEEMPAT MODEL SEBELUM TUNING

Grafik menunjukkan perbandingan akurasi dan log loss empat algoritma klasifikasi sebelum tuning. Decision Tree tampil terbaik dengan akurasi 85% dan log loss 0.41. Logistic Regression dan KNN menyusul dengan akurasi 78% dan log loss wajar. Naive Bayes terendah, dengan akurasi 76% dan log loss 1.25. Hasil ini menjadi gambaran awal performa model sebelum tuning.



HASIL EVALUASI MODEL DENGAN GRIDSEARCHCV

Results for Logistic Regression (Tuned):

Accuracy: 0.7879

Log Loss: 0.4554

Confusion Matrix:

```
[[275  34]
 [ 68 104]]
```

	precision	recall	f1-score	support
0	0.80	0.89	0.84	309
1	0.75	0.60	0.67	172
accuracy			0.79	481
macro avg	0.78	0.75	0.76	481
weighted avg	0.78	0.79	0.78	481

Results for Naïve Bayes (Tuned):

Accuracy: 0.7630

Log Loss: 1.2555

Confusion Matrix:

```
[[268  41]
 [ 73  99]]
```

	precision	recall	f1-score	support
0	0.79	0.87	0.82	309
1	0.71	0.58	0.63	172
accuracy			0.76	481
macro avg	0.75	0.72	0.73	481
weighted avg	0.76	0.76	0.76	481

Results for K-Nearest Neighbors (Tuned):

Accuracy: 0.7651

Log Loss: 0.4169

Confusion Matrix:

```
[[272  37]
 [ 76  96]]
```

	precision	recall	f1-score	support
0	0.78	0.88	0.83	309
1	0.72	0.56	0.63	172
accuracy			0.77	481
macro avg	0.75	0.72	0.73	481
weighted avg	0.76	0.77	0.76	481

Results for Decision Tree (Tuned):

Accuracy: 0.8399

Log Loss: 0.7052

Confusion Matrix:

```
[[255  54]
 [ 23 149]]
```



	precision	recall	f1-score	support
0	0.92	0.83	0.87	309
1	0.73	0.87	0.79	172
accuracy			0.84	481
macro avg	0.83	0.85	0.83	481
weighted avg	0.85	0.84	0.84	481

- **Decision Tree** memiliki performa terbaik dengan akurasi 85.2% dan F1-score tinggi serta seimbang.
- **Logistic Regression** cukup baik (akurasi 78.79%), namun cenderung kurang optimal pada kelas positif.
- **KNN** mencapai akurasi 77.34% namun memiliki bias terhadap kelas mayoritas.
- **Naive Bayes** memiliki akurasi 76.3% tapi log loss tinggi, serta performa buruk pada kelas minoritas.




HASIL PERBANDINGAN KINERJA KEEMPAT MODEL SETELAH DILAKUKAN HYPERPARAMETER TUNING DENGAN GRIDSEARCHCV

Setelah tuning dengan GridSearchCV, Decision Tree tetap unggul dengan akurasi tertinggi (>86%) dan log loss yang cukup rendah. KNN mencatat log loss terendah, sementara Naive Bayes masih terendah performanya. Secara keseluruhan, tuning meningkatkan kinerja semua model, dengan Decision Tree sebagai pilihan terbaik.



5. HASIL ANALISIS

Grafik menunjukkan perbandingan akurasi train dan test dari empat model klasifikasi. Decision Tree tampil paling seimbang (train 89%, test 86%) tanpa overfitting. Logistic Regression dan Naïve Bayes menunjukkan performa cukup baik dengan selisih akurasi kecil. KNN mengalami overfitting parah (train 100%, test 78%). Secara keseluruhan, Decision Tree menjadi model paling andal.



KESIMPULAN



Berdasarkan keseluruhan proses dan hasil yang diperoleh dalam tugas ini, dapat disimpulkan bahwa model Decision Tree merupakan algoritma terbaik untuk klasifikasi sindrom metabolik pada dataset yang digunakan. Hal ini didukung oleh akurasi tertinggi sebesar 85%, serta log loss yang relatif rendah, menunjukkan kemampuan model dalam memberikan prediksi yang akurat dan stabil. Model lain seperti Logistic Regression dan K-Nearest Neighbors juga menunjukkan performa yang baik setelah tuning, namun masih berada di bawah Decision Tree. Sementara itu, Naive Bayes, meskipun sederhana dan cepat, memiliki keterbatasan dalam menangani kompleksitas data ini, ditunjukkan oleh akurasi dan log loss yang paling rendah. Dengan demikian, pemilihan model yang tepat dan penyetelan parameter yang optimal sangat penting dalam meningkatkan kinerja model klasifikasi dalam pembelajaran mesin.

Kelompok 6

THANK YOU

